




¿Qué es y para qué sirve KNIME?

Es un software de código abierto con una interfaz visual e intuitiva que le permite crear análisis de cualquier nivel de complejidad, desde la automatización de hojas de cálculo hasta ETL y aprendizaje automático.

- Herramienta de software libre
- Desarrollado en la plataforma Eclipse y programado en Java
- Herramienta gráfica e interactiva y funciona con nodos (Java,Python,R,Matlab y Perl)
- Se conecta a bases de datos como Mongo, postgre o mysql



Si nos fijamos cada nodo tiene una especie de semáforo justo debajo del símbolo:

- Rojo: No está enlazado o no tiene datos
- Amarillo: Está enlazado pero no ejecutado
- Verde: ejecutado correctamente

¿Por qué KNIME para aplicaciones de datos?

KNIME proporciona un entorno intuitivo de arrastrar y soltar, tanto para crear como para implementar la ciencia de datos.

No se requiere codificación (a menos que lo desee)

Cree aplicaciones de datos e implementarlas utilizando el mismo entorno intuitivo sin tener que escribir una línea de código, a menos que lo desee.

Invocar modelos y análisis de cualquier nivel de complejidad

Implemente aplicaciones de datos de cualquier nivel de sofisticación, ya sea un simple formulario de aceptación de datos o un sofisticado análisis predictivo basado en ML.

Aplicar tanto la experiencia en datos como en el dominio

Diseñe aplicaciones de datos con capacidades interactivas para que pueda capturar la experiencia de dominio de sus homólogos de línea de negocio.

Implementar fácilmente sus aplicaciones de datos

Implemente cualquier flujo de trabajo como una aplicación de datos, sin experiencia en infraestructura. Comparta aplicaciones fácilmente a través de un enlace mientras garantiza la seguridad con el control de acceso basado en roles. Como alternativa, puede incrustar aplicaciones de datos en aplicaciones de terceros.

Explicar y aplicar sus resultados

Permite la creación rápida de prototipos y auditorías a través de la programación visual. Asegúrese de que cada paso lógico sea legible para las partes interesadas técnicas y no técnicas

Ventajas:

- Sistema libre
- Funciona en el propio equipo
- Visual e intuitiva
- Crear flujos de trabajo visuales
- Se integra con diferentes bases de datos, nodos, lenguajes de programación

Desventajas:

- Limita la potencia de cálculo (por funcionar en el propio equipo)
- En procesos de análisis largos se generan flujos muy largos y engorrosos

Extensiones:


- Acceso y procesamiento de tipos de datos complejos, así como el uso de algoritmos avanzados
- Desarrolladas y mantenidas por KNIME
- Algoritmo de aprendizaje profundo proporcionados por Keras
- Aprendizaje automático de alto rendimiento proporcionado por H2O, procesamiento de big data proporcionado por Abarne Spark
- Secuencias de comandos proporcionadas por python y R.

Segmentación no Jerárquica


K-means (nodo): se encarga de dividir en clusters las variables que van a ingresar en la segmentación.

Análisis Descriptivo:


- ROC Curve:** participación que puede tener cada una de las variables en la formación de los clusters según el área bajo la curva.
- Color Manager:** colores para los clusters.
- Statistics View:** Datos que queremos que nos aparezca en la tabla.
- Scatter Matrix:** Podemos ver cómo se comporta cada cluster a través de matrices, podemos ver cada cluster por separado o todos juntos.
- Scatter Plot:** Mezclamos cada cluster con la variable que queramos, por ejemplo para ver en que cluster está el salario más alto... Viene representado con una gráfica y con un color(seleccionado anteriormente) para cada cluster.
- Pie Chart:** nos muestra otra gráfica diferente con la participación de cada cluster.




ROC Curve:



Scatter Matrix:



Scatter Plot:



A partir de aquí podemos exportar los datos en un archivo de excel, quedaría hacer la caracterización a través de tablas dinámicas en excel cruzando las variables con los clusters. En el caso de una segmentación, buscamos que sea lo más homogéneo posible dentro de cada segmento y lo más heterogéneo posible entre segmentos.

RowID	Ciudad	Altura	Educacion	Genero	Estatura	Salario	Ciudad_cod	Altura_cod	Educacion	Genero_cod	Cluster
Row9	Buenos Air	bajo	Posgrado	Hombre	142	21361	1	1	1	1	cluster_2
Row10	Buenos Air	medio	Tecnico	Mujer	189	84386	1	2	2	2	cluster_1
Row39	Buenos Air	bajo	Primaria	Mujer	140	22437	1	1	3	2	cluster_0
Row61	Buenos Air	alto	Primaria	Mujer	197	40625	1	3	3	2	cluster_1
Row65	Buenos Air	alto	Tecnico	Mujer	140	80098	1	3	2	2	cluster_1
Row68	Buenos Air	medio	Secundaria	Mujer	143	79178	1	2	4	2	cluster_1
Row81	Buenos Air	bajo	Universitaria	Hombre	146	65290	1	1	5	1	cluster_2
Row82	Buenos Air	medio	Tecnico	Hombre	196	99304	1	2	2	1	cluster_2
Row90	Buenos Air	bajo	Tecnico	Hombre	131	38089	1	1	2	1	cluster_2
Row100	Buenos Air	medio	Tecnico	Hombre	194	52572	1	2	2	1	cluster_2
Row111	Buenos Air	medio	Tecnico	Hombre	176	67763	1	2	2	1	cluster_2
Row121	Buenos Air	bajo	Posgrado	Mujer	168	74396	1	1	1	2	cluster_0
Row127	Buenos Air	medio	Universitaria	Hombre	207	33595	1	2	5	1	cluster_2
Row129	Buenos Air	alto	Posgrado	Mujer	198	48243	1	3	1	2	cluster_1
Row138	Buenos Air	alto	Posgrado	Mujer	181	44737	1	3	1	2	cluster_1
Row144	Buenos Air	alto	Primaria	Hombre	161	47031	1	3	3	1	cluster_2
Row146	Buenos Air	medio	Posgrado	Hombre	156	39933	1	2	1	1	cluster_2
Row148	Buenos Air	alto	Tecnico	Hombre	178	81755	1	3	2	1	cluster_2
Row156	Buenos Air	bajo	Tecnico	Hombre	152	90529	1	1	2	1	cluster_2
Row165	Buenos Air	bajo	Primaria	Mujer	194	24163	1	1	3	2	cluster_3
Row176	Buenos Air	bajo	Primaria	Mujer	137	80456	1	1	3	2	cluster_0
Row181	Buenos Air	medio	Secundaria	Mujer	205	62213	1	2	4	2	cluster_3
Row184	Buenos Air	medio	Primaria	Mujer	199	27135	1	2	3	2	cluster_1
Row187	Buenos Air	bajo	Primaria	Hombre	178	95193	1	1	3	1	cluster_2
Row191	Buenos Air	alto	Primaria	Hombre	152	72841	1	3	3	1	cluster_2
Row197	Buenos Air	medio	Posgrado	Hombre	148	93035	1	2	1	1	cluster_2
Row208	Buenos Air	medio	Tecnico	Hombre	165	76605	1	2	2	1	cluster_2

Coeficiente de Silueta:


- Es una métrica útil para evaluar la calidad del segmento.
- El objetivo es identificar cuál es el n° óptimo de segmentos.
- La puntuación puede oscilar entre -1 y 1, mientras más cerca esté de 1 mejor.

Conectamos el coeficiente de Silueta a k-means a través de la primera flecha que es por dónde sale la base de datos.

En k-means seleccionamos el n° de clusters que queremos que haya y mediante el coeficiente de siluetas no solo podemos ver el coeficiente de silueta elemento a elemento si no que nos permite ver el promedio del coeficiente de silueta para cada cluster.


Lo malo que tiene el coef. de silueta es que hay que ir cambiando manualmente los nodos y escribiendolos en una tabla de excel, luego graficamos y en el n° de cluster donde está el coef. mayor, será el óptimo.

También se puede hacer a través de un método automatizado, optimizando el k-means, para hacerlo por este método es necesario haber instalado previamente el optimizador de k-means:




Segmentación Jerárquica

- No requiere que se pre establezca un número de clúster determinado
- Dendrograma, una especie de diagrama de árbol para visualizar análisis de conglomerados jerárquicos destacando las relaciones jerárquicas entre conglomerados.
- Funciona de forma aglomerativa.
- Agrupa jerárquicamente los datos de entrada utilizando una matriz de distancia
- Este nodo sólo funciona en conjuntos de datos pequeños porque tiene una complejidad cúbica.
- Heatmap requiere previa instalación en knime



Dendograma:



Segmentación espacial basada en densidad de aplicaciones con ruido.

DBSCAN es un algoritmo de clúster basado en densidad, porque encuentra un número de clúster en un conjunto de datos que contiene ruido y valores atípicos.

Es uno de los algoritmos de agrupamiento más usados en Segmentación.

Parámetros:

- Epsilon: distancia máxima entre dos muestras para que sea considerada como un clúster de la otra. Este es el parámetro más importante y por defecto es 0.5.
- Puntos mínimos: mínimo de muestras o puntos para formar un clúster, por defecto este valor es igual a 5.
- Métrica: la forma en la que se va a calcular la distancia entre los puntos, por defecto es la distancia Euclidiana.

Puntos:

- Punto central
- Punto de borde
- Punto de ruido

Análisis de clasificación

(Es una técnica supervisada)

Árbol de decisión

- Es un algoritmo predictivo de aprendizaje supervisado no paramétrico, que se utiliza para tareas de clasificación como de regresión. (Estructura jerárquica con nodo raíz, ramas, nodos internos y nodos hoja).
- Algoritmo más utilizado en Machine Learning por su sencilla implementación y fácil interpretación, además de determinar reglas de decisión permitiendo la toma de decisiones futuras.
- Existen diferentes tipos de árbol: CHAID, CHAID exhaustivo, CRT, QUEST, ID3, C4.5 Y CART.
- Sirve para abordar problemas tales como la clasificación, predicción y segmentación de datos para tomar decisiones futuras:
 - Segmentación
 - Clasificación
 - Predicción
 - Reducción de la dimensión de los datos
 - Identificación-interrelación
 - Recodificación

Ventajas:

- Fácil de interpretar
- Permite capturar relaciones no lineales
- Poca preparación o gestiones previas de los datos
- Algoritmo no paramétrico
- Flexibilidad
- Insensible a las relaciones subyacentes entre los atributos
- Selecciona las variables más importantes que permiten explicar la variable "Y".
- Sirven tanto para variables "Y" dependientes cualitativas como cuantitativas.
- Se pueden categorizar variables numéricas y variables cualitativas.

Desventajas:

- Propenso al sobreajuste
- Estimadores de alta varianza
- Sensible al desbalanceo
- Más costoso en comparación con otros algoritmos
- Se ven influenciados por los outliers

