


ORANGE DATA MINING



Orange Data Mining es un software de análisis de datos y visualización de fácil uso debido a su enfoque modular. Es una herramienta de código abierto muy poderosa para científicos de datos y analistas, ya que nos permite analizar y visualizar datos de manera muy intuitiva y gráfica.

Esta herramienta tiene una amplia gama de aplicaciones que van desde el análisis exploratorio de datos hasta el aprendizaje automático y la minería de datos.

Ahora vamos a ver un ejemplo de algunas herramientas del programa. Veamos cómo sería una vista global del programa y qué aspecto tendría una vez se van conectando los distintos módulos. A continuación pongo el enlace que lleva a la página web de Orange: <https://orangedatamining.com>



En este ejemplo hemos utilizado primero el módulo file para poder abrir un fichero y leerlo, en nuestro caso hemos utilizado el fichero iris.tab. Si conectamos ese fichero con el módulo Data Table, este nos va a mostrar una tabla con los datos del archivo.

Data Table - Orange

Info
150 instances (no missing data)
4 features
Target with 3 values
No meta attributes.

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes



Selection
☒ Select full rows

Restore Original Order
☒ Send Automatically

	iris	sepal length	sepal width	petal length	petal width
1	Iris-setosa	5.1	3.5	1.4	0.2
2	Iris-setosa	4.9	3.0	1.4	0.2
3	Iris-setosa	4.7	3.2	1.3	0.2
4	Iris-setosa	4.6	3.1	1.5	0.2
5	Iris-setosa	5.0	3.6	1.4	0.2
6	Iris-setosa	5.4	3.9	1.7	0.4
7	Iris-setosa	4.6	3.4	1.4	0.3
8	Iris-setosa	5.0	3.4	1.5	0.2
9	Iris-setosa	4.4	2.9	1.4	0.2
10	Iris-setosa	4.9	3.1	1.5	0.1
11	Iris-setosa	5.4	3.7	1.5	0.2
12	Iris-setosa	4.8	3.4	1.6	0.2
13	Iris-setosa	4.8	3.0	1.4	0.1
14	Iris-setosa	4.3	3.0	1.1	0.1
15	Iris-setosa	5.8	4.0	1.2	0.2
16	Iris-setosa	5.7	4.4	1.5	0.4
17	Iris-setosa	5.4	3.9	1.3	0.4
18	Iris-setosa	5.1	3.5	1.4	0.3
19	Iris-setosa	5.7	3.8	1.7	0.3
20	Iris-setosa	5.1	3.8	1.5	0.3
21	Iris-setosa	5.4	3.4	1.7	0.2
22	Iris-setosa	5.1	3.7	1.5	0.4
23	Iris-setosa	4.6	3.6	1.0	0.2
24	Iris-setosa	5.1	3.3	1.7	0.5
25	Iris-setosa	4.8	3.4	1.9	0.2
26	Iris-setosa	5.0	3.0	1.6	0.2
27	Iris-setosa	5.0	3.4	1.6	0.4
28	Iris-setosa	5.2	3.5	1.5	0.2

150 150 150


Con este módulo podemos ver cómo está dividida la tabla y el número de datos que tiene el fichero. También hay otros módulos como Scatter Plot y Distributions que sirven para visualizar los datos y ver cómo están distribuidos.



Tanto en la tabla como en el diagrama de puntos podemos seleccionar unos datos en concreto, que nos sean de interés, y trabajar con los datos escogidos y poder analizar solo ese conjunto de datos.

La comunicación entre los módulos se puede cambiar dando clic derecho sobre la línea que une los módulos y seleccionando si queremos mandar todos los datos o solo los que hemos seleccionado.

El módulo Hierarchical Clustering precedido por el módulo Distance, donde elegimos que distancia queremos usar, nos va a dar la distancia que hay entre los datos y nos va a agrupar los datos según la distancia entre ellos en clusters.




Orange incluye módulos de modelización de datos, en el ejemplo que estamos viendo usamos dos de ellos para predecir tres nuevos datos que hemos añadido manualmente donde falta especificar el tipo de iris que es. Estos modelos que usamos son Logistic Regression y Tree, y si conectamos estos a un módulo Predictions, este nos va a predecir qué tipo de iris sería cada una de las tres filas de datos que hemos introducido.

Predictions - Orange


Show probabilities for (None)

	Tree	Logistic Regression	iris	sepal length	sepal width	petal length	petal width
1	Iris-virginica	Iris-virginica	?	4.3	2.5	5.2	1.5
2	Iris-virginica	Iris-virginica	?	5.1	3.1	6.0	2.1
3	Iris-setosa	Iris-setosa	?	4.8	3.6	1.2	0.3


Veamos cómo es el modelo de predicción Tree que hemos usado para predecir esos datos que hemos introducido nuevos.




Por último, vamos a ver como el propio Orange tiene módulos que nos permiten ver cómo son de fiables esos modelos de predicción de datos que hemos usado. Para ello primero empezaremos colocando tres diferentes modelos de predicción Tree, Logistic Regression y Random Forest, este último es un poco más complejo que los dos anteriores pero con mayor fiabilidad de predicción en algunos casos. Para evaluar su fiabilidad vamos a usar el módulo Test and Score y después conectado a él Confusion Matrix para que nos muestre los resultados del test.



Esta imagen anterior muestra una forma de cómo evaluar la capacidad de predicción de estos modelos. A continuación veamos cómo sería la matriz de confusión del modelo Random Forest, donde los cuadrados en rojo es el número de datos que no se pueden predecir.



Y si pulsamos la opción Select Misclassified vamos a seleccionar los datos que se nos saldrían fuera de nuestra predicción. Estos podemos mostrarlos en un diagrama de puntos.



Este es un informe superficial donde explico brevemente algunos módulos básicos de Orange Data Mining, esta herramienta es mucho más extensas y se pueden hacer unos análisis mucho más extensos y detallados e incluye algoritmos para el estudio de redes neuronales.

Miguel Calles Diaz